

1. Global Optimality of $p_g = p_{data}$

- proposition 1) G 가 고정된 경우, 최적의 discriminator D ,

$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

(proof) $\rightarrow G$ 가 주어졌을 때 $V(G, D)$ 를 최대화 하려함

$$V(G, D) = \int_x p_{data}(x) \log(D(x)) dx + \int_z p_g(z) \log(1 - D(G(z))) dz$$

$$= \int_x \left[\underbrace{p_{data}(x)}_{=a} \log(D(x)) + \underbrace{p_g(G(x))}_{=b} \log(1 - D(x)) \right] dx$$

$\rightarrow (a, b) \in \mathbb{R}^2 \setminus \{0, 0\}$ 이 아닌 실수 순서쌍 (a, b) 에 대해

$$y \rightarrow a \log(y) + b \log(1-y)$$

\uparrow 상수항으로 처리 \hookrightarrow 최대일 때 y 값을 찾아야 하므로

$$\begin{aligned} \text{미분하면, } \frac{a}{y} - \frac{b}{1-y} &= 0 \Rightarrow a(1-y) = by \\ a - ay &= by \\ a &= (a+b)y \\ \therefore y &= \frac{a}{a+b} \end{aligned}$$

$y = \frac{a}{a+b}$ 일 때 최대이므로

$$\Rightarrow D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

$V(G, D)$ 를 대서 써보면

$$C(G) = \max_D V(G, D)$$

$$= E_{x \sim p_{data}} [\log D_G^*(x)] + E_{z \sim p_g} [\log(1 - D_G^*(G(z)))]$$

$$= E_{x \sim p_{data}} [\log D_G^*(x)] + E_{x \sim p_g} [\log(1 - D_G^*(x))]$$

$$= E_{x \sim p_{data}} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + E_{x \sim p_g} \left[\log \frac{p_g(x)}{p_{data}(x) + p_g(x)} \right]$$

- theorem 1) The global minimum of the virtual training criterion $C(G)$ is

achieved if and only if $p_g = p_{data}$. At that point, $C(G)$ achieves the

value $-\log 4$.

(proof) $p_g = p_{data}$ 인 p_g 에 대해 $D_G^*(z) = \frac{1}{2}$ 이고, $C(G)$ 에 대입하면 $\log \frac{1}{2} + \log \frac{1}{2} = -\log 4$

→ 이 값이 $C(G)$ 의 최솟값 → G 입장에서 가장 이상적임!

$$E_{x \sim p_{data}} [-\log 2] + E_{x \sim p_g} [-\log 2] = -\log 4$$

$$\Rightarrow C(G) = C(G) + \log 4 - \log 4 \quad (0)$$

$$= -\log 4 + E_{x \sim p_{data}} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \right] + E_{x \sim p_g} \left[\log \frac{p_g(x)}{p_{data}(x) + p_g(x)} \right] \xrightarrow{\log 2 + \log 2}$$

$$= -\log 4 + \underbrace{KL(p_{data} \parallel \frac{p_{data} + p_g}{2}) + KL(p_g \parallel \frac{p_{data} + p_g}{2})}_{\text{Kullback-Leibler divergence}} = \frac{1}{2} D_{KL}(p_{data} \parallel \frac{p_{data} + p_g}{2}) + \frac{1}{2} D_{KL}(p_g \parallel \frac{p_{data} + p_g}{2})$$

$$= -\log 4 + 2 \cdot JSD(p_{data} \parallel p_g)$$

→ Jensen-Shannon divergence

$$JSD(p \parallel q) = \frac{1}{2} D_{KL}(p \parallel m) + \frac{1}{2} D_{KL}(q \parallel m)$$

+ 두 분포가 완전히 일치할 때만 0

$D_{KL}(p \parallel q) = \sum p(x) \log \frac{p(x)}{q(x)}$
 ⇒ p와 q 분포일수록
 같아질수록
 다른지 측정하는 값

∴ $C(G)$ 의 global minimum은 $-\log 4$ 이며 그 유일한 해는 $p_{data} = p_g$

2. Convergence of Algorithm 1

- 이 알고리즘이 문제를 얼마나 잘 풀어주는지 증명

- Proposition 2) G, D 가 충분한 용량을 가지고 있고, Algorithm이 각 step에서

discriminator가 주어진 G 에 대해 optimum에 도달하도록 허용하고,

$$p_g \text{가 업데이트되어 기원을 개선한다면, } E_{x \sim p_{data}} [\log D_G^*(x)] + E_{x \sim p_g} [\log (1 - D_G^*(x))]$$

= p_g 는 p_{data} 를 추정

(proof) $V(G, D) = U(p_g, D)$ 를 p_g 의 함수로 생각

→ $V(p_g, D)$ 는 p_g 에서 convex → 최댓값에 도달한 지점에서의 도함수 포함

if $f(p_g) = \sup_{D \in \mathcal{D}} f(p_g, D)$ and $f(p_g)$ is convex in p_g every p_g
 then $\exists f^* p_g \in \mathcal{P}$ if $D^* = \arg \sup_{D \in \mathcal{D}} f(p_g, D)$

⇒ 대응하는 G 가 주어진 최적의 D 에서 p_g 에 대한 gradient-descent update
 와 동일

→ p_g 에 대한 적분 update 만으로도 $p_g \rightarrow p_{data}$ 수렴함